

DA AQUISIÇÃO À RECORRÊNCIA

Relatório executivo de comportamento, pagamentos, retenção e propensão à recompra

Brazilian E-Commerce Public Dataset by Olist

Período observado: setembro de 2016 a agosto de 2018 | Universo principal: pedidos entregues

Tese executiva

O crescimento observado é fortemente orientado por aquisição. A principal oportunidade de criação de valor está em converter a primeira compra em relacionamento recorrente — especialmente nos primeiros 30–90 dias — usando segmentação, cross-sell e priorização por propensão.

Nota de escopo

Este relatório analisa um conjunto público e histórico de transações do marketplace Olist. Os resultados descrevem o período e a amostra observados; não representam a situação financeira ou operacional atual da empresa Olist.

1. Resumo executivo

A análise integrada de qualidade de dados, pagamentos, RFM, recompra, coortes e machine learning aponta um negócio com forte escala de aquisição, mas baixa conversão da primeira compra em recorrência. O valor econômico está concentrado em uma parcela relativamente pequena da base, enquanto a maior parte dos clientes compra apenas uma vez.

96.478	93.358	R\$ 15,42 mi	R\$ 159,85
Pedidos entregues	Clientes únicos	Receita observada	Ticket médio/pedido

3,0%	2,28%	54% da receita	1,85x
Clientes recorrentes	Recompra em 90 dias	Top 20% da base	Lift modelo - Top 10%

Cinco conclusões para decisão

- Aquisição cresceu em escala ao longo do período, mas retenção mensal permaneceu abaixo de 1%, indicando dependência relevante de novas compras de primeira vez.
- A recorrência é rara: 97% dos clientes fizeram apenas um pedido entregue; ainda assim, clientes recorrentes apresentam valor econômico desproporcional e merecem proteção.
- A janela de 30–90 dias é o principal momento de conversão para segunda compra: metade dos clientes que recompram o faz em até 30 dias e cerca de 68% em até 90 dias.
- O valor é concentrado: os 10% maiores clientes respondem por 38% da receita e os 20% maiores por 54%.
- Um modelo de propensão consegue enriquecer a priorização comercial, mas o desempenho é modesto e sofre drift temporal; deve ser usado como ranking de ação, não como previsão determinística.

Implicação para investidores

O principal upside analítico não está em aumentar apenas o volume de aquisição, mas em melhorar a economia da base adquirida: segunda compra, cross-sell, retenção de alto valor e disciplina de CRM. Pequenas melhorias na recorrência podem ter efeito relevante sobre LTV, CAC payback e eficiência de crescimento — métricas que não estão disponíveis diretamente no dataset, mas que deveriam orientar os próximos testes de negócio.

2. Escopo analítico e governança

O projeto consolidou nove tabelas públicas em uma arquitetura analítica com granularidade controlada. Pagamentos e itens foram agregados antes do join com pedidos, evitando multiplicação de linhas e dupla contagem de receita. Para análises de cliente, a chave adotada foi customer_unique_id; customer_id foi tratado como identificador transacional.

Camada	Regra metodológica	Por que importa
Pedidos	Uma linha por order_id	Evita dupla contagem entre itens e pagamentos
Clientes	customer_unique_id	Permite acompanhar o mesmo consumidor em pedidos distintos

Camada	Regra metodológica	Por que importa
Universe comportamental	order_status = delivered	Foca compras concluídas
Data de compra	order_purchase_timestamp	Base comum para RFM, coortes e recompra
Modelo	Split temporal	Reduz leakage e simula uso real com passado → futuro

Qualidade relevante

- 99.441 pedidos no dataset original; 96.478 entregues no universo principal.
- 93.358 clientes únicos no universo entregue.
- Duplicidade estrutural relevante em geolocalização foi documentada; reviews possuem duplicidades de review_id e muitos comentários ausentes, por isso reviews não foram usados no modelo atual.
- A camada de pagamentos possui múltiplos registros por pedido em alguns casos; análises financeiras sempre consolidam o valor no nível correto.

3. Pagamentos: facilitação da compra, não retenção por si só

O cartão de crédito domina o comportamento de pagamento: aproximadamente 73,9% dos registros de pagamento são cartão, contra 19,0% boleto, 5,6% voucher e 1,5% débito. O parcelamento é, portanto, uma característica estrutural da experiência de compra.




Figura 1. Participação nos registros de pagamento do dataset de pagamentos.

No recorte de clientes elegíveis à recompra em 90 dias, o meio de pagamento isoladamente tem baixo poder discriminatório: cartão 2,27%, boleto 2,24%, voucher 2,55% e débito 2,18%. Em outras palavras, o instrumento de pagamento parece explicar mais a forma de financiar a primeira compra do que a decisão de voltar a comprar.

Sinal útil: parcelamento

A recompra em 90 dias cresce de 2,09% entre compras em 1x para 3,07% entre compras em 7–12 parcelas. A faixa de 13+ parcelas chega a 4,76%, mas tem apenas 126 clientes e deve ser lida com cautela. O padrão é associativo, não causal.

4. Economia da base: muito volume de compradores únicos, valor concentrado

Dos 93.358 clientes analisados, 90.557 fizeram apenas um pedido entregue. Apenas 2.801 clientes — 3,0% da base — realizaram dois ou mais pedidos. Mesmo assim, esses clientes recorrentes respondem por cerca de 5,6% da receita observada, sugerindo que recorrência e valor caminham juntos.




Figura 2. Concentração acumulada da receita por clientes ordenados por valor monetário.

A concentração reforça a importância de retenção seletiva: os 10% clientes de maior valor concentram aproximadamente 38% da receita; os 20% maiores, 54%; e metade da base, 81%. Uma estratégia uniforme de CRM desperdiça orçamento ao tratar clientes de valor muito diferente da mesma forma.




Figura 3. Segmentação RFM - participação aproximada em clientes e receita dos principais segmentos.

Dois segmentos merecem atenção imediata. “At Risk” representa cerca de 16% dos clientes, mas 29% da receita histórica; “New High Value” representa 15% da base e 28% da receita. O primeiro pede estratégia de reativação; o segundo, estratégia de segunda compra enquanto o relacionamento ainda está recente.

Segmento	Clientes	Receita	Leitura executiva
At Risk	14.737 (16%)	R\$ 4,51 mi (29%)	Alto valor histórico, baixa recência: recuperar antes de perder
New High Value	14.394 (15%)	R\$ 4,35 mi (28%)	Compra recente e valiosa: converter para segunda compra
Promising	10.556 (11%)	R\$ 2,33 mi (15%)	Valor médio relevante, ainda sem recorrência
Hibernating	30.081 (32%)	R\$ 2,05 mi (13%)	Grande audiência, baixo valor individual: reativar de forma seletiva
Loyal Customers	1.587 (2%)	R\$ 0,50 mi (3%)	Base pequena, recorrente e estratégica para retenção

5. Segunda compra: a janela crítica é 30-90 dias

A taxa bruta de clientes com pelo menos duas compras entregues é 3,0%, mas essa métrica sofre censura: clientes adquiridos no fim da série tiveram menos tempo para recomprar. Quando a análise considera somente clientes com janela completa, a taxa cresce com o horizonte de observação.




Figura 4. Taxa de recompra por horizonte, considerando apenas clientes elegíveis a cada janela.

Entre os 2.801 clientes que efetivamente repetiram compra, a mediana até a segunda ordem é de aproximadamente 29 dias. Cerca de 50,4% recompram em até 30 dias e 68,1% em até 90 dias. Isso sugere que a ativação pós-compra não deve esperar o cliente “sumir”: a melhor janela de estímulo começa logo após a primeira experiência.

A categoria também importa. Entre categorias com base mínima relevante, `home_appliances` apresentou recompra em 90 dias de 7,69%, `fashion_bags_accessories` 4,39%, `bed_bath_table` 3,96% e `furniture_decor` 3,52%. Além disso, 54,0% das segundas compras ocorreram em categoria diferente da primeira.

Implicação comercial

O dado favorece uma estratégia de cross-sell orientada à segunda compra. Como mais da metade dos repeaters migra de categoria, limitar a comunicação ao mesmo produto/categoria pode perder parte importante do potencial de relacionamento.

6. Coortes: aquisição cresceu mais rápido que relacionamento

As coortes mostram expansão expressiva do volume adquirido ao longo da série — de 717 clientes em janeiro de 2017 para patamares próximos de 6–7 mil clientes mensais em vários meses de 2018. Contudo, a retenção mensal exata permanece baixa.




Figura 5. Retenção no mês exato versus recompra acumulada por maturidade da coorte.

A retenção ponderada é de 0,48% em M1, 0,25% em M3, 0,23% em M6 e 0,17% em M12. Já entre clientes com 12 meses completos de observação, a recompra acumulada atinge 2,16% até M1, 2,69% até M3, 3,51% até M6 e 4,57% até M12.

Essa diferença é importante: retenção mensal responde “quem comprou exatamente naquele mês?”, enquanto recompra acumulada responde “quem já voltou pelo menos uma vez até esse ponto?”. Para investidores, a segunda métrica é mais intuitiva para avaliar conversão à recorrência; a primeira é útil para avaliar hábito e cadência.

Tese de crescimento

O dataset evidencia escala de aquisição, mas não demonstra formação de hábito de compra. Sem melhora de retenção, crescimento tende a depender mais de aquisição contínua — o que, em um negócio real, aumenta a importância de controlar CAC, margem de contribuição e payback.

7. Propensão à recompra: priorização, não promessa

O Notebook 06 treinou modelos usando apenas informações disponíveis na primeira compra e split temporal. O Random Forest foi selecionado na validação e testado nos clientes mais recentes, preservando uma avaliação out-of-time.

Métrica	Validação	Teste recente	Interpretação
PR-AUC	0,0474	0,0293	Sinal preditivo existe, mas é modesto
ROC-AUC	0,6459	0,5898	Capacidade de ordenação cai no período recente
Lift Top 10%	2,73x	1,85x	Top score recompra acima da média

Métrica	Validação	Teste recente	Interpretação
Precision Top 10%	-	3,19%	Contra prevalência de 1,73% no teste
Recall Top 10%	-	18,46%	10% da base concentra ~18,5% dos repurchasers




Figura 6. Desempenho do ranking de propensão no teste temporal.

As principais variáveis associadas à propensão foram valor da primeira compra, proporção de frete, valor de produtos, frete absoluto, número de parcelas, horário/mês da compra, categorias e diversidade de itens. Essas importâncias são preditivas, não causais.

Governança do modelo

O lift caiu de 2,73x na validação para 1,85x no teste, evidenciando drift temporal. Em produção, seria necessário monitorar estabilidade, retreinar periodicamente e testar incrementalidade com experimentos controlados.

8. Implicações para investidores e prioridades de ação

A análise sugere quatro frentes de criação de valor. Elas não substituem métricas financeiras corporativas, mas indicam onde um e-commerce com este padrão transacional deveria concentrar testes e capital operacional.

Prioridade	Evidência	Ação recomendada	Métrica de sucesso
1. Converter 1ª → 2ª compra	68% dos repeaters retornam em até 90 dias	Jornada pós-compra 7/30/60/90 dias com incentivo e cross-sell	Recompra 90d, margem incremental, CAC payback
2. Proteger alto valor	Top 20% = 54% da receita; At Risk = 29%	CRM diferenciado para At Risk, Loyal e Champions	Receita retida, reativação, churn de valor
3. Explorar cross-sell	54% das 2ª compras mudam de categoria	Recomendação de categorias adjacentes por perfil da 1ª compra	Attach rate, receita por cliente, margem

Prioridade	Evidência	Ação recomendada	Métrica de sucesso
4. Priorizar orçamento	Top 10% do modelo = 1,85x lift	Usar score para ordenar público e combinar com regras RFM	Lift, ROI incremental, custo por recompra

O ponto central é transformar aquisição em relacionamento. Um plano de investimento baseado apenas em GMV ou volume de pedidos pode parecer saudável enquanto esconde uma base pouco recorrente. A combinação de retenção, concentração de valor e propensão permite avaliar a qualidade do crescimento, não apenas sua escala.

Próximos experimentos recomendados

- A/B test de incentivo à segunda compra em 30–90 dias, mensurando uplift incremental e margem — não apenas conversão bruta.
- Cross-sell por matriz de transição de categorias, priorizando categorias de aquisição com maior recorrência observada.
- Modelo enriquecido com experiência logística e satisfação (atraso, review_score), testando ganho de PR-AUC e lift.
- LTV e unit economics com custo de aquisição, margem, descontos e custo de contato, permitindo calcular ROI por segmento.
- Monitoramento mensal de coortes e modelo: aquisição, M1/M3/M6, recompra 90d, receita acumulada por cliente, drift e lift.

9. Riscos, limitações e leitura responsável

- Base histórica (2016–2018): não deve ser extrapolada como retrato atual do mercado ou da empresa.
- Dataset transacional não contém CAC, margem, custo de mídia, desconto incremental ou custo de CRM; portanto, não permite estimar ROI ou LTV econômico completo.
- Retenção e recompra são observacionais. Diferenças por pagamento, categoria ou parcelamento não demonstram causalidade.
- Clientes recentes têm menor janela de observação; por isso foram usadas métricas com elegibilidade temporal e células censuradas como NaN em coortes.
- O modelo apresenta poder preditivo limitado e drift temporal; uso recomendado é priorização de testes, com validação causal posterior.
- O universo principal exclui pedidos não entregues. Uma análise de cancelamento, atraso e satisfação poderia revelar novas alavancas de retenção.

10. Storytelling recomendado para apresentação a investidores

A apresentação deve conduzir o público de escala → qualidade da base → oportunidade de recorrência → capacidade de ação. O objetivo não é mostrar todos os notebooks, mas responder uma pergunta: “o crescimento observado está criando relacionamento econômico durável?”

Slide	Mensagem principal	Visual recomendado
1. A tese	A próxima alavanca de valor é transformar aquisição em recorrência	4 KPIs: clientes, receita, 3% recorrência, 54% receita top 20%
2. Base confiável	Granularidade e governança evitam dupla contagem	Fluxo de dados: pedidos + pagamentos + itens → cliente
3. Como o cliente paga	Cartão domina; pagamento sozinho pouco explica recompra	Mix de pagamento + taxas 90d por meio
4. Onde está o valor	97% compram uma vez; receita é concentrada	Curva de concentração + RFM

Slide	Mensagem principal	Visual recomendado
5. Quando agir	A janela crítica é 30–90 dias	Curva de recompra por horizonte
6. Qualidade do crescimento	Aquisição escala, retenção mensal continua baixa	Heatmap/coorte + curva cumulativa
7. Como priorizar	Top 10% do score tem 1,85x a taxa média	Lift por parcela da base
8. Plano de criação de valor	Segunda compra + cross-sell + CRM de alto valor + testes causais	Roadmap 90 dias com KPIs

Frase de encerramento sugerida

A análise não aponta falta de demanda; aponta uma oportunidade de monetizar melhor a demanda já adquirida. O próximo salto de qualidade é medir e aumentar a conversão da primeira compra em relacionamento recorrente, com disciplina de margem e experimentação.

Apêndice A — KPIs consolidados

Tema	KPI	Valor
Escala	Pedidos entregues	96.478
Escala	Clientes únicos	93.358
Escala	Receita no universo entregue	R\$ 15,42 mi
Escala	Ticket médio por pedido	R\$ 159,85
Recorrência	Clientes com 2+ pedidos	2.801 (3,0%)
Recorrência	Recompra 30 dias	1,58%
Recorrência	Recompra 90 dias	2,28%
Recorrência	Recompra 180 dias	3,11%
Tempo	Mediana até 2ª compra	~29 dias
Tempo	Repeaters que voltam até 90d	68,1%
Valor	Top 10% da base	38% da receita
Valor	Top 20% da base	54% da receita
RFM	At Risk	29% da receita
RFM	New High Value	28% da receita
Coortes	Retenção M1	0,48%
Coortes	Recompra acumulada M12*	4,57%
Modelo	Lift Top 10% - teste	1,85x
Modelo	Precision Top 10% - teste	3,19%
Modelo	ROC-AUC - teste	0,5898

* População com 12 meses completos de observação.

Apêndice B — Linha de evidência por notebook

Notebook	Papel no relatório
01 — Data Quality & Preparation	Qualidade, chaves, granularidade e construção da orders_base
02 — Payment Analysis	Mix de pagamento, ticket, parcelamento e comportamento financeiro
03 — Customer RFM	Recência, frequência, valor, concentração e segmentos acionáveis
04 — Repurchase Analysis	Taxa e tempo de segunda compra, categorias, pagamento e target 90d
05 — Cohort & Retention	Retenção M0–M12, recompra acumulada e valor por safra
06 — Repurchase Prediction	Ranking de propensão, lift, campanha e governança de modelo