

OLIST CUSTOMER ANALYTICS

Relatório Executivo para Investidores

Pagamentos • RFM • Recompra • Coortes • Machine Learning

Brazilian E-Commerce Public Dataset by Olist

Eduardo Figueiredo

Tese executiva

A principal oportunidade está na conversão da primeira para a segunda compra. O projeto combina comportamento transacional, valor do cliente, coortes e propensão à recompra para priorizar ações de CRM e reduzir a dependência de aquisição contínua.

1. Resumo Executivo

O projeto analisa aproximadamente 100 mil pedidos do marketplace Olist, entre 2016 e 2018, com foco em comportamento de pagamento, valor do cliente, recorrência, retenção e propensão à recompra.

A análise foi estruturada para separar métricas descritivas de métricas temporalmente comparáveis. Em recompra, somente clientes com janela de observação completa entram nos denominadores de 30, 60, 90 e 180 dias. Em coortes, a maturidade considera o último mês calendário completo, evitando penalizar safras recentes por meses parcialmente observados.

Indicador	Resultado de referência	Leitura
Clientes com 2+ pedidos	~3,0%	Recorrência estruturalmente baixa
Recompra em até 90 dias	~2,28%	Target operacional para CRM/modelagem
Mediana até 2ª compra	~29 dias	Janela curta após aquisição
2ª compra em até 90 dias	~68% dos repeaters	Concentração temporal da recompra
Top 20% de clientes	>50% da receita	Valor concentrado
Lift Top 10% - modelo	~1,85x	Ranking útil para priorização

Nota: os números acima refletem a execução de referência do projeto e devem ser reconfirmados após a reexecução completa dos notebooks revisados.

Implicação para investidores

O desafio não está apenas em adquirir clientes, mas em ampliar o valor econômico da base existente. A baixa recorrência aumenta a dependência de novas aquisições; por outro lado, a concentração de valor e a janela de 30-90 dias criam uma oportunidade clara de retenção seletiva.

2. Base Analítica e Governança

A arquitetura do projeto evita dupla contagem de receita e mantém as granularidades separadas. Pagamentos e itens são agregados antes de joins no nível do pedido.

- `customer_unique_id` é o identificador usado para recorrência e retenção.
- `orders_base` mantém uma linha por pedido.
- Valores ausentes de `payment_value` não são convertidos silenciosamente para zero em análises financeiras.
- Sanity checks validam unicidade, integridade temporal e consistência das métricas.
- Os notebooks são executados em sequência, com outputs processados reutilizados nas etapas posteriores.

Pipeline analítico

Data Quality → Payments → RFM → Repurchase → Cohorts → Repurchase Prediction

3. Comportamento de Pagamentos

O projeto diferencia dois conceitos que frequentemente são misturados em análises de pagamento:

Associação ao meio de pagamento: percentual de pedidos em que um meio aparece. Como um pedido pode usar mais de um meio, as participações podem somar mais de 100%.

Meio principal: meio responsável pelo maior valor financeiro do pedido. Cada pedido possui apenas um meio principal e as participações somam 100%.

O parcelamento é interpretado principalmente dentro de pedidos cujo meio principal é cartão de crédito. Registros com `payment_installments = 0` são preservados na base bruta, mas excluídos das análises específicas de parcelamento.

Leitura de negócio

Meio de pagamento funciona melhor como sinal complementar do que como explicação isolada de recorrência. Seu valor analítico cresce quando combinado com ticket, categoria, frete, número de itens e momento da aquisição.

4. Valor do Cliente e Segmentação RFM

A segmentação RFM combina Recency, Frequency e Monetary para identificar clientes de maior valor, clientes recentes e clientes historicamente relevantes que apresentam risco de esfriamento.

Como a base é fortemente concentrada em `frequency = 1`, o score de frequência utiliza faixas comportamentais, evitando criar quintis artificiais entre clientes com o mesmo número de pedidos.

Segmento	Objetivo	Ação sugerida
Champions	Defender valor	Benefícios, cross-sell, referrals
Loyal Customers	Expandir share of wallet	Bundles e recomendação personalizada
New High Value	Converter ticket em recorrência	Onboarding e 2ª compra rápida
At Risk / Can't Lose Them	Recuperar valor histórico	Win-back seletivo
Hibernating	Controlar custo	Comunicação de baixo custo

Concentração econômica

Na execução de referência, aproximadamente 20% dos clientes concentram mais de 50% da receita observada. Isso reforça a necessidade de diferenciar estratégias de relacionamento por valor e recência.

5. Recompra: da Primeira para a Segunda Compra

Neste projeto, 'primeira compra' significa o primeiro pedido entregue observado do consumidor. A análise acompanha a segunda compra entregue e mede o tempo até a recompra.

Para reduzir censura à direita, as taxas em 30, 60, 90 e 180 dias consideram apenas clientes cuja primeira compra ocorreu cedo o suficiente para completar a respectiva janela.

Janela	Uso
30 dias	Ativação imediata e pós-compra
60 dias	Relacionamento de curto prazo
90 dias	Janela principal de CRM e target de modelagem
180 dias	Leitura ampliada de retorno

Janela crítica

Na execução de referência, a mediana até a segunda compra é próxima de 29 dias e cerca de 68% das segundas compras observadas ocorrem em até 90 dias. Isso torna os primeiros meses após a aquisição um período prioritário para CRM.

Categoria e expansão de relacionamento

A segunda compra não precisa ocorrer na mesma categoria dominante da primeira. Esse comportamento cria duas frentes complementares: continuidade/reposição para categorias naturalmente recorrentes e cross-sell para expansão da cesta.

6. Coortes, Retenção e Valor Econômico

A análise de coortes acompanha clientes por mês de aquisição e separa três conceitos: retenção mensal exata, recompra acumulada e valor econômico.

Retenção mensal exata: Percentual da coorte que comprou exatamente em Mk.

Recompra acumulada: Percentual da população madura que já realizou uma segunda compra até Mk.

Receita acumulada por cliente: Valor acumulado da coorte dividido pelo número de clientes originalmente adquiridos.

Revenue Index

Revenue Index Mk = Receita da coorte em Mk / Receita da coorte em M0

O Revenue Index não representa retenção de clientes e não deve ser interpretado como SaaS NRR. Ele pode superar 100% quando a receita de um mês posterior excede a receita do mês de aquisição.

Para evitar viés no final da série, a maturidade das coortes utiliza o último mês calendário completo. Meses ainda não observáveis aparecem como NaN, e não como zero.

7. Repurchase Prediction

O modelo estima a propensão de uma segunda compra em até 90 dias. O score é calculado após a conclusão da primeira compra entregue e utiliza somente atributos originados nesse primeiro pedido.

O split é temporal por coorte mensal: coortes inteiras são alocadas em treino, validação ou teste, evitando que a mesma safra apareça em conjuntos diferentes.

Métrica	Resultado de referência
PR-AUC teste	0,029
ROC-AUC teste	0,59
Lift@Top10%	1,85x
Recall@Top10%	18,5%
Precision@Top10%	3,19%
Taxa natural teste	1,73%

A avaliação prioriza PR-AUC, Lift@K, Recall@K e Precision@K. Acurácia não é adequada como métrica principal em um evento raro.

Uso recomendado

O modelo deve ser usado como ranking de priorização, e não como previsão determinística. Na execução de referência, o Top 10% do ranking concentra uma taxa de recompra de aproximadamente 3,19%, contra 1,73% na base de teste.

Importância e governança

A interpretação principal utiliza permutation importance no conjunto de teste. Importância preditiva significa contribuição ao poder de ordenação do modelo, não relação causal.

Quedas de PR-AUC ou Lift ao longo do tempo podem indicar drift e justificar monitoramento e retreino.

8. Recomendações Estratégicas

1. **Programa de Segunda Compra** - Ativar jornadas de CRM nos primeiros 30-90 dias após a primeira compra entregue.
2. **Cross-Sell** - Explorar categorias complementares e comportamento entre primeira e segunda compra.
3. **CRM Baseado em Valor** - Usar segmentos RFM para diferenciar intensidade, custo e benefício das ações.
4. **Campanhas por Propensão** - Priorizar Top 5%, 10% ou 20% do ranking conforme orçamento e capacidade operacional.
5. **Scorecard por Coorte** - Monitorar M1, M3, M6, recompra acumulada, Revenue Index e valor acumulado por cliente.

9. Limitações e Riscos de Interpretação

- Os dados cobrem 2016-2018 e não representam necessariamente a operação atual da Olist.
- Associação estatística não implica causalidade.
- Monetary representa valor pago, não margem.
- O dataset não contém CAC, custo promocional ou margem por pedido.
- Clientes adquiridos no fim da série têm menor tempo de acompanhamento.
- Revenue Index não representa retenção de clientes.
- Receita acumulada por cliente é proxy descritiva de LTV observado, não CLV predito.
- O target de recompra é raro e gera forte desbalanceamento.
- Importância de feature não implica que alterar a feature causará maior recompra.
- Medir efeito incremental de campanhas exige teste A/B ou uplift modeling.

10. Conclusão

A análise mostra que o principal ponto de criação de valor está na transição entre a primeira e a segunda compra. A combinação de pagamentos, RFM, recompra, coortes e Machine Learning permite identificar quem gera mais valor, quando a recompra acontece e quais clientes podem ser priorizados em ações futuras.

Mensagem final

A oportunidade estratégica é evoluir de uma lógica centrada em aquisição para uma lógica de aquisição + ativação + retenção seletiva. A conversão da 1ª para a 2ª compra é o ponto central dessa jornada.